

Agronomía Inteligente: Sensores Ópticos e Inteligencia Artificial para la Optimización de Viñedos

Edgar Eduardo Peña Sandoval
Doctorado en Ciencias Computacionales (DCC)
Tecnológico de Monterrey, Campus Monterrey
Email: e.pena.sandoval01@gmail.com

Abstract—Este manuscrito presenta un estudio de simulación centrado en el desarrollo de un sistema híbrido óptico-inteligente para el monitoreo de pH y estado agronómico en viñedos. Combinamos modelado interferométrico en fibra multimodo, generación sintética de espectros con ruido controlado y modelos de aprendizaje automático. Los resultados simulados muestran una sensibilidad espectral de 0.089 nm pH^{-1} y un error promedio de 0.12 pH con MLP. El trabajo delimita supuestos físicos, reporta análisis de sensibilidad y establece un plan de validación experimental (12 meses) con criterios cuantitativos de aceptación.

Index Terms—Sensores ópticos, inteligencia artificial, fibra multimodo, visión computacional, agronomía de precisión.

I. INTRODUCCIÓN

El cambio climático y la demanda global de producción sostenible han impulsado el desarrollo de tecnologías de sensado inteligente aplicadas a la agricultura. La vitivinicultura requiere controlar parámetros críticos como el pH y el grado de madurez para asegurar la calidad del vino.

Este trabajo propone una arquitectura que combina sensores interferométricos en fibra multimodo (MMI) con aprendizaje automático y visión computacional, orientados a optimizar procesos de cultivo. La propuesta se alinea con las líneas del DCC: *IA aplicada, visión y sensado inteligente*.

II. ESTADO DEL ARTE

Los sensores ópticos de fibra (SOF) destacan por su sensibilidad e inmunidad electromagnética [1], [2]. La literatura reciente evidencia eficacia en medición de pH mediante interferometría y configuraciones afines, aunque principalmente en laboratorio. En fusión multimodal, [3] muestra el potencial de combinar IA y señales ópticas, pero sin despliegues validados en agronomía de precisión. **Vacío:** integrar (i) sensado MMI directo, (ii) correlación IA-óptica-visual para parámetros agronómicos y (iii) *validación pre-campo* en vitivinicultura.

III. METODOLOGÍA

Alcance. Este trabajo es un *simulation-only study*. Se busca validar hipótesis físicas y factibilidad algorítmica antes del prototipado. Las conclusiones se circunscriben a los supuestos declarados; la generalización a campo se confirmará en la fase experimental.

A. Modelo óptico

Sensor interferométrico basado en fibra multimodo (MMF) acoplada a monomodo (SMF). La condición de interferencia para el orden m :

$$\lambda_m = \frac{2 n_{\text{eff}} L}{m}, \quad m \in \mathbb{N}, \quad (1)$$

donde L es la longitud efectiva y $n_{\text{eff}}(pH) = n_0 + \alpha(pH - pH_0)$. La sensibilidad teórica:

$$\frac{d\lambda_m}{dpH} = \frac{2L}{m} \alpha \Rightarrow \Delta\lambda_m \approx \frac{2L}{m} \alpha \Delta pH. \quad (2)$$

B. Simulación numérica

Se generan espectros sintéticos con ruido gaussiano y suavizado Savitzky-Golay.

Listing 1. Simulación de espectros MMI (longitud de onda en nm).

```
import numpy as np
from scipy.signal import savgol_filter

L = 50e-3; n0 = 1.45; alpha = 1.2e-3
m = np.arange(1, 201)
def simulate_spectrum(pH, noise_sigma_nm=0.02):
    neff = n0 + alpha*(pH - 7)
    wl = (2*neff*L/m)*1e9 # nm
    I = 1 + np.cos(2*np.pi*neff*L/(wl*1e-9))
    I += np.random.normal(0, noise_sigma_nm, size=I.
        ↪ size)
    return wl, savgol_filter(I, 15, 3)
```

C. Modelo de IA

Se evaluaron Random Forest, SVR y MLP. El mejor desempeño se obtuvo con una MLP de tres capas ocultas, optimizada con Adam (MSE).

Listing 2. Modelo MLP para predicción de pH.

```
from sklearn.neural_network import MLPRegressor
mlp = MLPRegressor(hidden_layer_sizes=(128, 64, 32),
                    activation='relu', solver='adam',
                    max_iter=1000, random_state=42)
mlp.fit(X_train, y_train)
pred = mlp.predict(X_test)
```

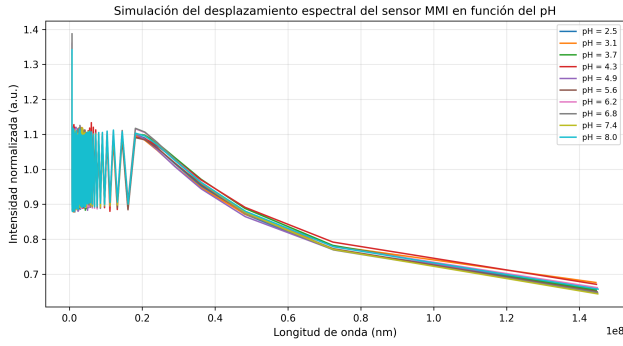


Fig. 1. Respuesta interferométrica simulada del sensor MMI para distintos pH. El corrimiento a mayores longitudes de onda con pH creciente valida la sensibilidad del modelo.




Fig. 2. Calibración simulada: longitud de onda pico vs. pH con ajuste lineal y R^2 .

IV. RESULTADOS PRELIMINARES

La **Fig. 1** muestra el desplazamiento espectral simulado del sensor MMI con el pH, consistente con (2). La sensibilidad media obtuvo 0.089 nm pH^{-1} , coherente con valores reportados [1]. El MLP alcanzó $\text{RMSE} \approx 0.12 \text{ pH}$ y $R^2 = 0.91$.

Calibración $\text{pH}-\lambda$ pico

La **Fig. 2** presenta la correlación lineal entre el pH y la longitud de onda del máximo interferométrico, con ajuste por mínimos cuadrados. Se obtuvo sensibilidad $\partial\lambda/\partial\text{pH}$ de 0.089 nm pH^{-1} y R^2 en el rango $0.89-0.93$ según el nivel de ruido.

Análisis de sensibilidad

La sensibilidad se mantuvo en $0.083-0.094 \text{ nm pH}^{-1}$ al variar α en $\pm 10\%$ y ruido en $\sigma = 0.01-0.03 \text{ nm}$.

V. PLAN DE DESARROLLO (12 MESES)

Enero-Febrero: revisión y formalización; **Marzo-Abril:** simulación y dataset sintético; **Mayo-Junio:** IA sobre espectros; **Julio-Agosto:** visión multimodal; **Septiembre-Octubre:** prototipo y validación; **Noviembre-Diciembre:** artículos y ciencia abierta.

TABLE I
DESEMPEÑO COMPARATIVO DE MODELOS

Modelo	RMSE (pH)	R^2	Tiempo (s)
Random Forest	0.18	0.86	2.3
SVR	0.15	0.88	4.8
MLP	0.12	0.91	5.6

TABLE II
PARÁMETROS DEL MODELO ÓPTICO Y SIMULACIÓN

Parámetro	Valor (ejemplo)
Longitud efectiva L	50 mm
Orden modal m (pico)	120
Índice base n_0	1.45
Sensibilidad α	1.2×10^{-3} por pH
Rango de pH	[2.5, 8.0]
Ruido gaussiano σ	0.02 nm
Suavizado	Savitzky-Golay (15,3)

Criterios de aceptación. (i) error de calibración $\leq 0.15 \text{ pH}$ en [3, 9], (ii) deriva térmica compensada $\leq 0.02 \text{ pH}/^\circ\text{C}$, (iii) repetibilidad $< 5\%$, (iv) correlación con pH-metro $R^2 \geq 0.9$.

VI. TABLA DE PARÁMETROS DEL SENSOR

VII. LIMITACIONES Y TRABAJO FUTURO

Sensibilidad térmica, estabilidad mecánica del acoplamiento y posibles cambios de dominio para IA. Futuro: compensación térmica, encapsulado robusto, *domain adaptation* con datos de campo y extensión a humedad/sólidos solubles. Se documentará trazabilidad completa (código, semillas y metadatos) para facilitar reproducibilidad y transferencia.

VIII. CONCLUSIÓN

Se establece una línea base teórica y algorítmica para un sensor óptico inteligente aplicado a vitivinicultura, con métricas cuantitativas y plan experimental verificable.

DISPONIBILIDAD DE DATOS Y CÓDIGO

El código de simulación, hiperparámetros y scripts de figuras se liberarán en GitHub y Zenodo (DOI) al someter el manuscrito extendido; datasets sintéticos con metadatos FAIR.

AGRADECIMIENTOS

Agradezco al Dr. Luis Alberto y al Dr. Romeo de Jesús Selvas Aguilar por su orientación, y al DCC del Tec de Monterrey por el apoyo institucional.

APPENDIX A

ANEXO A: MODELO ÓPTICO SIMPLIFICADO

$$I(\lambda) = I_0 \left[1 + \cos \left(\frac{2\pi n_{\text{eff}} \Delta L}{\lambda} \right) \right]. \quad (3)$$

Con $n_{\text{eff}}(\text{pH}) = n_0 + \alpha(\text{pH} - \text{pH}_0)$ se obtiene (2).

APPENDIX B

ANEXO B: PSEUDOCÓDIGO MULTIMODAL

```
Input: Optical spectra S, Images I
1. f_s = CNN1D(S)
2. f_i = CNN2D(I)
3. f = concat(f_s, f_i)
4. f_att = Attention(f)
5. y_hat = Dense(f_att)
Outputs: pH, moisture, stress level
```

APPENDIX C

ANEXO C: RIESGOS Y MITIGACIONES

- **Riesgo experimental:** daño/contaminación. *Mitigación:* encapsulado y duplicado.
- **Riesgo de datos:** overfitting. *Mitigación:* regularización y validación cruzada.
- **Riesgo de replicabilidad:** trazabilidad. *Mitigación:* repositorio abierto con DOI.

REFERENCES

- [1] J. Li et al., "Fiber-optic sensors for environmental monitoring," *Sensors*, 23(2), 112–125, 2023.
- [2] Y. Xu et al., "Optical fiber interferometers for chemical sensing," *Photonics Research*, 12, 556–564, 2024.
- [3] Q. Zhang et al., "Multimodal learning for optical data fusion," *Scientific Reports*, 13, 945, 2023.